Mineração de proxies DORA em repositórios open-source: validade e sensibilidade das definições operacionais

Davi Érico[1], **Gustavo Prehl**[1], **Lucas Resende**[1]

[1]Engenharia de Software
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)

Abstract. *This study proposes mining software delivery proxies from public GitHub repositories using GitHub Actions. Releases, commit timestamps and workflow runs support alternative operational definitions of DORA metrics. In the 300 selected repositories, the median project publishes one release every four weeks, and lead time per release exceeds lead time per commit (251 h versus 169 h). The two change failure rate proxies diverge (medians 0.054 for CI failures and 0.292 for corrective releases), as do the DORA categories: no project is Elite in frequency, while 77% are Elite in CI failure rate. Deployment frequency is positively correlated with both change failure rate variants (Spearman* $\rho = 0.182$ *for CI failures and* 0.567 *for corrective releases), contrary to the DORA claim that speed and stability do not compete. Across 12 tests with Holm correction, only lead time differs significantly, by main language and by contributor quartile, with small to medium effects. A single-rater validation, not linked to the frozen dataset, of the corrective release heuristic on 283 releases yields precision 0.238, recall 0.870 and F1 0.374, suggesting overestimation but not directly validating the dataset.*

Resumo. *Este estudo propõe minerar proxies de entrega de software em repositórios públicos do GitHub que utilizam GitHub Actions. Releases, datas de commits e execuções de workflows sustentam definições operacionais alternativas das métricas DORA. Nos 300 repositórios selecionados, o projeto mediano publica uma release a cada quatro semanas, e o lead time por release supera o por commit (251 h contra 169 h). As duas variantes de taxa de falha divergem (medianas de 0,054 para falhas de CI e 0,292 para releases corretivas), assim como as categorias DORA: nenhum projeto é Elite em frequência, enquanto 77% são Elite em falha de CI. A frequência de deploy correlaciona-se positivamente com as duas variantes de taxa de falha (Spearman* $\rho = 0{,}182$ *para falhas de CI e* $0{,}567$ *para releases corretivas), contrariando a afirmação do DORA de que velocidade e estabilidade não competem. Em 12 testes com correção de Holm, só o lead time difere significativamente, por linguagem principal e por quartil de contribuidores, com efeitos pequenos a médios. Uma validação com avaliador único da heurística de release corretiva, não vinculada ao dataset congelado, em 283 releases, resulta em precisão 0,238, recall 0,870 e F1 0,374; os rótulos sugerem superestimação, mas não validam diretamente o dataset.*

1. Introdução

DORA motiva avaliar em conjunto frequência e estabilidade de entrega [Forsgren et al. 2018, DORA 2026]. Releases, commits e registros de integração

contínua são proxies: não demonstram implantação ou incidente em produção. O estudo adota as quatro métricas e os cortes de classificação fixados pelo enunciado.

O objetivo deste estudo é caracterizar proxies DORA em projetos open-source que utilizam GitHub Actions e avaliar a confiança nas comparações resultantes. As questões de pesquisa investigam frequência de releases (RQ01), lead time (RQ02), taxas de falha (RQ03), recuperação de workflows (RQ04), associação entre frequência e falha (RQ05), diferenças entre características dos projetos (RQ06) e sensibilidade da classificação às definições operacionais (RQ07).

O protocolo prevê doze meses e ao menos 300 repositórios públicos elegíveis (mais de 1.000 estrelas, cinco releases e 50 execuções válidas de Actions no branch padrão). O lead time compara a mediana por release, do commit mais antigo à publicação, com a mediana por commit incluído. A paginação da API evita truncar silenciosamente a comparação [GitHub 2026].

A janela S02 foi de 6/10/2025 a 7/10/2026 (UTC-3), fim exclusivo: 366 dias. Gustavo autorizou a extensão de um dia para compatibilizar a coleta com 183 repositórios de outro integrante; a confirmação docente registrada na `main` refere-se a doze meses, e não há aprovação da extensão registrada. O manifesto do piloto de 100 repositórios registra execução interrompida. Esta versão relata RQ01–RQ07 nos 300 repositórios congelados e a validação parcial do CFR (b).

O protocolo previa três avaliadores em 60 repositórios, com cinco releases cada. A validação disponível é de avaliador único e não está ligada ao dataset congelado; esse limite é discutido na Seção 3.4. A RQ07 compara combinações de releases, pré-releases, tags e variantes de lead time e CFR.

1.1. Hipóteses a priori

As hipóteses abaixo acompanham o protocolo versionado antes da coleta deste estudo. O repositório não registra uma revisão conjunta das hipóteses pelo grupo. Elas expressam expectativas a confrontar com os dados, não resultados observados. Revisões posteriores à observação dos resultados deverão ser identificadas como exploratórias.

H01 (RQ01). Espera-se heterogeneidade na frequência de releases, com concentração abaixo de uma entrega semanal, pois projetos podem agrupar mudanças em ciclos distintos de publicação.

H02 (RQ02). Espera-se que a variante por release apresente, em geral, lead times superiores aos da variante por commit, pela influência de commits antigos. Não é uma identidade matemática: as variantes ponderam as releases de formas diferentes.

H03 (RQ03). Espera-se divergência entre CFR baseado em CI e baseado em releases corretivas, pois capturam eventos distintos. Não se antecipa ordenação obrigatória entre seus valores.

H04 (RQ04). Espera-se distribuição assimétrica dos tempos de recuperação, com muitos episódios curtos e alguns prolongados. Episódios não encerrados durante a janela deverão permanecer registrados como censurados.

H05 (RQ05). Espera-se associação monotônica fraca ou não positiva entre frequência e CFR. Spearman será calculado para ambas as variantes de CFR, sem interpretar associação como causalidade.

H06 (RQ06). Espera-se diferença entre subgrupos em pelo menos uma métrica. O protocolo fixa linguagem principal, quartis de estrelas e quartis de contribuidores como fatores antes de observar resultados.

H07 (RQ07). Espera-se que parte dos repositórios mude de categoria DORA ao alterar as definições de entrega, lead time e CFR, especialmente próximo aos cortes de classificação.

2. Metodologia

2.1. População, seleção e amostra analisada

A população-alvo são repositórios públicos do GitHub com mais de 1.000 estrelas que usam GitHub Actions. A busca `stars:>1000`, ordenada por estrelas, informou 65.512 repositórios. Os 1.800 mais populares formaram a lista de candidatos. Destes, 1.563 usam Actions. São elegíveis os que têm, na janela, pelo menos cinco releases publicadas no histórico do branch padrão e pelo menos 50 workflow runs válidos disparados por `push` nesse branch. Para limitar o custo da coleta, também ficaram de fora repositórios com mais de 500 releases ou mais de 1.000 runs de `push` na janela. Restaram 311 elegíveis, e os 300 mais populares formaram a seleção. A amostra é intencional (por popularidade), não aleatória.

A coleta foi dividida nos índices 0–182 e 183–299. Na segunda parte, 17 repositórios não cumpriram o mínimo de releases na verificação de ancestralidade e foram substituídos pelos próximos elegíveis em ordem de estrelas (`data/selecao-amostra-revisada.json`).

Amostra analisada. O dataset congelado (`data/amostra_completa.json.gz`, coleta de 13 de outubro de 2026) reúne 183 e 117 repositórios, totalizando os 300 selecionados. A janela e os critérios são comuns às partes; todos usam a heurística v2. A amostra varia de cerca de 24 mil a 289 mil estrelas e não representa projetos menos populares.

2.2. Janela e unidades

A janela vai de 6 de outubro de 2025 a 7 de outubro de 2026 (UTC-3), com fim exclusivo, e tem 366 dias. O dia além dos doze meses é uma exceção de compatibilidade, discutida na introdução. Releases e runs entram pela data de publicação e de criação, respectivamente. Commits incluídos em releases da janela podem ser anteriores a ela.

2.3. Métricas

Frequência (RQ01): releases publicadas na janela divididas pela sua duração em semanas. **Lead time (RQ02):** cada release é comparada com a anterior. A variante (a) é a mediana, por repositório, do intervalo entre a publicação e o commit mais antigo da release. A variante (b) é a mediana sobre todos os commits incluídos. **CFR (RQ03):** a variante (a) é a proporção de runs de CI com falha entre os runs com sucesso ou falha. A variante (b) é a proporção de releases seguidas, em até sete dias, por uma release corretiva. Releases dos últimos sete dias da janela são censuradas. A heurística v2 considera corretiva a release que só altera o *patch* semver, ou em que pelo menos metade dos commits cita `revert`, `hotfix` ou `fix`. **Recuperação (RQ04):** horas entre o início da primeira

falha e o próximo sucesso no mesmo workflow. Episódios abertos no fim da janela são censurados.

A classificação DORA usa os cortes do enunciado. A categoria geral é a mediana das quatro notas (Elite 4 a Low 1), arredondada para baixo, e só é emitida quando as quatro métricas são observadas. A configuração de referência C1 usa releases publicadas, lead time (a) e CFR (a). As configurações C2 (com pré-releases, lead time (b) e CFR (b)) e C3 (tags) servem à RQ07. Ausências nunca são imputadas como zero, e cada uma tem o motivo registrado.

2.4. Validação manual

O protocolo previa 60 repositórios, cinco releases por projeto e rotulagem cega por três avaliadores. O relatório disponível cobre 283 releases em 58 repositórios, mas seu hash de origem difere do dataset congelado; os resultados não validam diretamente o CFR (b) dos 300 repositórios. Só um avaliador humano concluiu a rotulagem, sem consenso (Seção 3.4).

2.5. Análise estatística

As métricas são descritas por mediana e IQR. A RQ05 usa a correlação de Spearman entre a frequência e cada CFR. A RQ06 usa Kruskal-Wallis, com ε^2 como tamanho de efeito, para linguagem principal e quartis de estrelas e de contribuidores, fatores fixados antes da coleta. Comparações múltiplas são corrigidas por Holm ($\alpha = 0{,}05$). A RQ07 compara as classificações por percentual de mudança de categoria e kappa de Cohen ponderado linear. Todas as análises são reexecutáveis a partir do dataset congelado (`python -m lab03.analysis.*`).

3. Resultados

Os resultados abaixo usam os 300 repositórios do dataset congelado (`data/amostra_completa.json.gz`), achatados em uma linha por repositório (`analysis/base_repositorios.csv`). Seguindo o protocolo, reportam-se mediana e IQR. Métricas ausentes não são imputadas, e por isso o n varia por análise. Toda correção para comparações múltiplas usa Holm, com $\alpha = 0{,}05$.

3.1. RQ01 a RQ04: métricas DORA

A Tabela 1 resume as quatro métricas por repositório. O n válido varia porque 11 repositórios não têm release avaliável para lead time e CFR (b), e 32 não têm episódio de recuperação encerrado.

RQ01. A mediana é de uma release a cada quatro semanas; 266 dos 300 repositórios (89%) publicam menos de uma por semana. Nove não publicaram release na janela.

RQ02. O lead time por release supera o por commit nas medianas (250,8 h contra 169,4 h) e em 212 dos 289 repositórios (73%). A variante (a) dá o mesmo peso a cada release; a (b), a cada commit (Figura 1).

RQ03. Nos 289 repositórios com ambos os valores, a mediana da diferença CFR (b) − CFR (a) é 0,200 (IQR 0,409; Figura 2). A validação parcial (Seção 3.4) indica superestimação pelo CFR (b); nenhuma variante observa falhas em produção.

Tabela 1. RQ01–RQ04: distribuição por repositório. Fontes: `analysis/rq01_rq02/` e `analysis/rq03_rq04/` (`lab03.analysis.rq01_rq02`, `lab03.analysis.rq03_rq04`).

Métrica	n	Mediana	[Q1–Q3]
Frequência (releases/semana)	300	0,268	[0,134–0,555]
Lead time (a), por release (h)	289	250,8	[70,3–756,5]
Lead time (b), por commit (h)	289	169,4	[53,9–546,0]
CFR (a), runs de CI com falha	300	0,054	[0,020–0,142]
CFR (b), release corretiva em 7 dias	289	0,292	[0,125–0,522]
Recuperação (h)	268	4,89	[0,84–21,48]

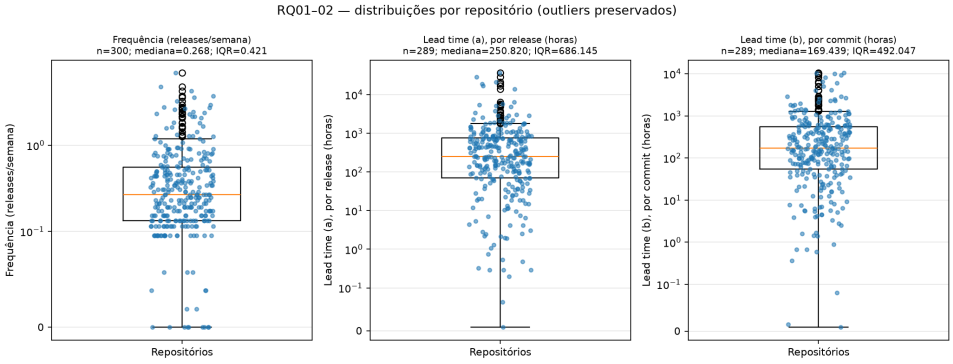


Figura 1. RQ01–RQ02: distribuições de frequência e lead time (a) e (b), em escala *symlog*, com todos os outliers preservados.

RQ04. A recuperação tem mediana de 4,9 h e Q3 de 21,5 h. Foram censurados 75 dos 4.119 episódios (1,8%) e 251 das 8.518 releases do CFR (b) (2,9%), sem imputação.

A Tabela 2 mostra a classificação DORA de referência (C1), com os cortes do enunciado. A categoria geral é a mediana das quatro pontuações, arredondada para baixo, e só é emitida quando as quatro métricas são observadas. Por isso 40 repositórios ficam sem categoria geral.

Tabela 2. Classificação DORA C1 por métrica e geral (300 repositórios). Fonte: `analysis/c1_reference/c1_resultados.json` (`lab03.analysis.c1_reference`).

Métrica	Elite	High	Medium	Low	Não classif.
Frequência	0	34	130	136	0
Lead time (a)	42	72	98	77	11
CFR (a)	230	40	17	13	0
Recuperação	77	135	40	16	32
Geral	17	89	130	24	40

Nenhum repositório é Elite em frequência, e 45% são Low; em contraste, 77% são Elite em CFR (a). A categoria geral concentra-se em Medium e High. A RQ07 avalia a sensibilidade à variante de CFR.

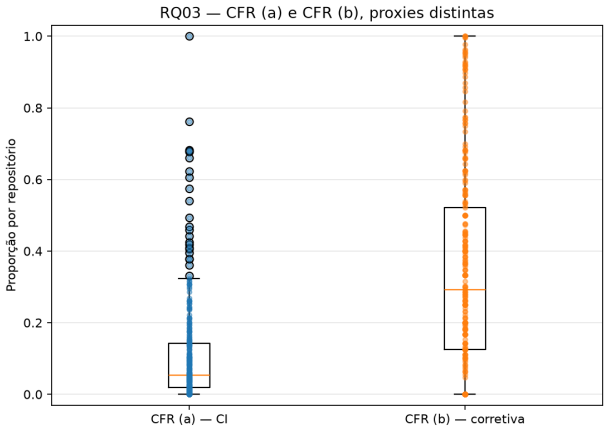


Figura 2. RQ03: comparação entre CFR (a) e CFR (b) por repositório.

3.2. RQ05: frequência de deploy e taxa de falha

A Tabela 3 apresenta a correlação de Spearman entre a frequência de deploy e cada variante de CFR, com n pareado (repositórios com as duas métricas). As duas associações são positivas: repositórios que publicam mais releases têm, em postos, CFR *maior*. A associação com o CFR (a), de CI, é fraca, mas significativa ($\rho = 0{,}182$; $p_{Holm} = 0{,}002$). Com o CFR (b), de release corretiva, ela é forte ($\rho = 0{,}567$; $p_{Holm} < 0{,}001$). A Figura 3 mostra as dispersões.

Tabela 3. RQ05: Spearman entre frequência (releases/semana) e CFR. Fonte: `analysis/rq05/rq05_resultados.json` (`lab03.analysis.rq05`).

Variante de CFR	n	CFR mediano [IQR]	ρ	p_{Holm}	CFR $= 0$
(a) runs de CI com falha	300	0,054 [0,020–0,142]	0,182	0,002	24
(b) release corretiva em 7 dias	289	0,292 [0,125–0,522]	0,567	$1{,}1 \times 10^{-25}$	52

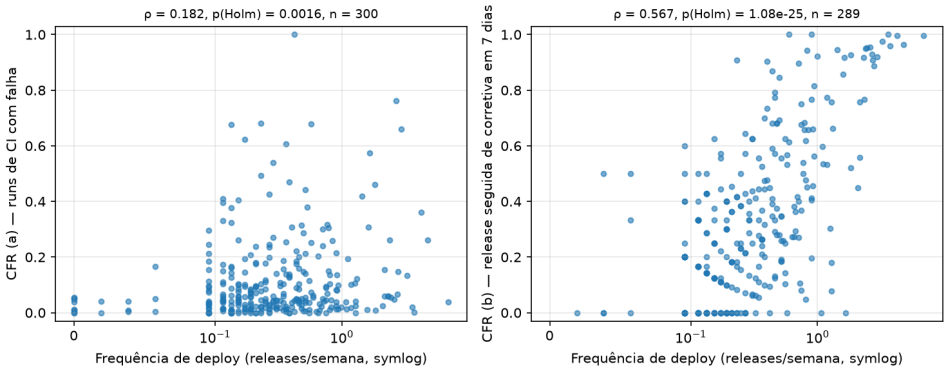


Figura 3. RQ05: frequência de deploy (eixo X em escala *symlog*, que mantém os 9 repositórios sem release na janela) versus CFR (a) e CFR (b).

As associações positivas não sustentam a expectativa de que velocidade e estabilidade não competem. A associação mais forte com CFR (b) pode decorrer da janela de sete dias da heurística; a validação parcial (Seção 3.4) também indica superestimação. São associações observacionais, sem inferência causal.

3.3. RQ06: características dos repositórios

Os fatores pré-registrados são linguagem principal (TypeScript 77, Python 60, "Outras" 51, que reúne as 16 linguagens com menos de 10 repositórios, Go 31, JavaScript 31, Rust 25, C++ 13 e Java 10), quartis de estrelas (75 por quartil) e quartis de contribuidores (74 a 76 por quartil). Dois repositórios não têm linguagem principal. As métricas são as da configuração de referência C1. A Tabela 4 resume os 12 testes de Kruskal-Wallis, com tamanho de efeito $\varepsilon^2 = H/(n-1)$.

Tabela 4. RQ06: Kruskal-Wallis por fator e métrica (C1). Células: ε^2 (p_{Holm}); * indica significância após Holm. Fonte: `analysis/rq06/rq06_resultados.json` (`lab03.analysis.rq06`).

Fator	Frequência $n = 300$	Lead time (a) $n = 289$	CFR (a) $n = 300$	Recuperação $n = 268$
Linguagem ($k = 8$)	0,055 (0,22)	0,099 (0,002)*	0,041 (0,82)	0,027 (1,00)
Estrelas ($k = 4$)	0,010 (1,00)	0,002 (1,00)	0,022 (0,82)	0,011 (1,00)
Contribuidores ($k = 4$)	0,007 (1,00)	0,053 (0,017)*	0,001 (1,00)	0,017 (1,00)

Dois testes permanecem significativos após Holm, ambos para lead time (a): linguagem ($\varepsilon^2 = 0{,}099$, médio) e quartil de contribuidores ($\varepsilon^2 = 0{,}053$, pequeno). As medianas são menores em TypeScript e Python que em Rust e C++, e nos dois primeiros quartis de contribuidores que nos dois últimos. Não houve testes *post hoc*; tipo de projeto não foi controlado e está rotulado somente nos 60 repositórios da amostra-ouro.

3.4. Validação do CFR (b): avaliador único

O protocolo previa três avaliadores e consenso; somente B rotulou releases na primeira rodada, e a segunda não foi realizada. Os rótulos de A são rascunhos auxiliares, não uma segunda avaliação. Portanto, não há consenso nem medida de confiabilidade entre avaliadores; o resultado é uma *validação de avaliador único*.

A validação disponível cobre 283 releases em 58 repositórios. Seu hash de origem (87656c1c9637) difere do dataset congelado (bbc652390d9f); o estado é `not_linked_to_frozen_dataset`. Assim, a tabela descreve essa amostra, mas não valida diretamente o CFR (b) dos 300 repositórios analisados. A Tabela 5 compara a heurística v2 com B.

Tabela 5. CFR (b): heurística v2 Œ avaliador B (283 releases, 58 repositórios). IC 95% de Wilson. Fonte: `analysis/validacao_cfr_b/resultados.json` (`lab03.analysis.cfr_b_validation`).

B \ heurística	não	sim	Métrica	Valor [IC 95%]
não	109	128	Precisão	0,238 [0,180–0,308]
sim	6	40	Recall	0,870 [0,743–0,939]
			F1	0,374

Com precisão 0,238 e $F_1 = 0,374$, abaixo do limiar de 0,70, a heurística tende a superestimar o CFR (b). Os intervalos de Wilson não ajustam o agrupamento de releases por repositório; os limites desta validação são retomados na Seção 5.

3.5. RQ07: sensibilidade da classificação

Comparando a categoria geral entre as variantes, há mudança em todos os pares (Tabela 6). Só entram repositórios classificados nas duas variantes; os demais são excluídos, sem imputação. O kappa de Cohen usa pesos lineares para a ordem Low $<$ Medium $<$ High $<$ Elite.

Tabela 6. RQ07: mudanças de categoria geral e concordância entre variantes (300 repositórios). Fonte: `analysis/rq07/rq07_resultados.md` (`lab03.analysis.rq07`).

Par	n	Excluídos	Mudaram (%)	Subiram	Desceram	κ linear
C1×C2	259	41	115 (44,4%)	36	79	0,311
C1×C3	260	40	74 (28,5%)	59	15	0,625
C2×C3	261	39	107 (41,0%)	99	8	0,428

Os pares incluem somente repositórios classificados em ambas as variantes. Mudanças que envolvem C2 podem refletir o erro do CFR (b), cuja validação obteve $F_1 = 0,374$; os resultados não implicam causalidade.

4. Discussão

Esta seção confronta as hipóteses prévias com os 300 repositórios. As RQ01–RQ04 e RQ07 sustentam H01–H04 e H07; H05 é refutada, e H06 é sustentada apenas para lead time (2 dos 12 testes).

H05 refutada. As correlações de Spearman são positivas para o CFR (a) ($\rho = 0{,}182$) e mais fortes para o CFR (b) ($\rho = 0{,}567$). A janela de sete dias da heurística pode associar mecanicamente maior frequência a mais releases corretivas; os resultados não mostram que publicar mais cause mais falhas.

H06 parcialmente sustentada. Só 2 dos 12 testes permanecem significativos após Holm, ambos para lead time; seus efeitos são médio ($\varepsilon^2 = 0{,}099$) e pequeno ($\varepsilon^2 = 0{,}053$). Sem testes *post hoc*, não se identificam pares de grupos diferentes, e resultados não significativos não demonstram ausência de efeito.

Proxies e sensibilidade. Na amostra de validação não ligada ao dataset congelado, a heurística do CFR (b) obteve $F_1 = 0{,}374$, abaixo do limiar de 0,70. A categoria geral mudou em 44,4%, 28,5% e 41,0% nos pares C1×C2, C1×C3 e C2×C3, respectivamente. Essas mudanças são descritivas da amostra e não medem incidentes em produção; C2 também herda a incerteza da heurística. As demais limitações e mitigações estão detalhadas na Seção 5.

Distribuições. Outliers foram preservados; as análises usam mediana, IQR e testes por postos, e as figuras empregam escala *symlog*.

5. Ameaças à validade

As quatro categorias clássicas de ameaças à validade organizam esta análise [Wohlin et al. 2012].

5.1. Validade de construto

As métricas são proxies, não medidas de entrega em produção: release não demonstra implantação ou adoção, e falha de CI não equivale a falha em produção. Os CFRs (a) e (b) capturam eventos distintos, nenhum deles incidentes reais.

Na amostra de validação (283 releases, 58 repositórios), com avaliador único, a heurística teve precisão 0,238 (IC 95% de Wilson [0,180; 0,308]), recall 0,870 e $F_1 = 0,374$, abaixo do limiar 0,70 (`analysis/validacao_cfr_b/resultados.md`). B confirmou 40 das 168 releases marcadas; a heurística perdeu seis das 46 corretivas segundo B. A amostra não está ligada ao dataset congelado (`analysis/rq03_rq04/`); esses valores não validam diretamente o CFR (b) dos 300 repositórios.

Também mudaram de categoria 44,4% (C1×C2; $\kappa = 0,311$), 28,5% (C1×C3; $\kappa = 0,625$) e 41,0% (C2×C3; $\kappa = 0,428$) dos repositórios comparáveis (`analysis/rq07/rq07_resultados.md`). C2 usa o CFR (b); essas diferenças não isolam a definição do erro da heurística nem indicam desempenho em produção.

5.2. Validade interna

As análises são observacionais. Idade e atividade podem afetar releases, commits e CI, mas a RQ06 compara apenas linguagem e quartis de estrelas e contribuidores; não ajusta por esses fatores. Seus dois resultados significativos entre 12 testes não estabelecem causalidade (`analysis/rq06/rq06_resultados.md`).

No CFR (b), uma alteração apenas de *patch* ou mensagens com `fix`, `hotfix` ou `revert` podem marcar uma release sem evidência de falha anterior. O $F_1 = 0,374$ limita as conclusões com essa variável. Mitigação: rotulagem independente por múltiplos avaliadores, consenso e reavaliação da heurística em amostra separada.

O lead time usa `commit.author.date`, que pode divergir da entrada no branch padrão; rebase e *squash merge* afetam a relação entre datas de commits e releases. A análise não estima esse efeito. Futuras replicações podem comparar a data de autoria com a de integração e reportar a sensibilidade.

Há censura à direita: 251 de 8.518 releases do CFR (b) (2,9%) não têm os sete dias seguintes completos, e 75 de 4.119 episódios de recuperação (1,8%) não se encerraram (`analysis/rq03_rq04/rq03_rq04_resultados.md`, seção *Censura*). Foram mantidos sem imputação, mas a janela pode subcontar eventos tardios. Mitigação: acompanhar o CFR por mais sete dias e reportar e analisar separadamente os censurados.

5.3. Validade externa

O estudo abrange projetos públicos com mais de 1.000 estrelas, GitHub Actions, ao menos cinco releases e 50 execuções válidas de `push`, sob os limites de coleta do protocolo. Dos 311 elegíveis, foram escolhidos os 300 mais populares (Seção 2.1); a seleção intencional não representa projetos menos populares, comerciais ou equipes em geral.

O tipo de projeto foi rotulado apenas nos 60 repositórios da amostra-ouro; não se generaliza sua distribuição ou seus resultados aos 300 sem nova rotulagem.

5.4. Validade de conclusão

A RQ06 aplicou Holm aos 12 testes de Kruskal–Wallis: dois foram significativos, ambos para lead time, com efeitos $\varepsilon^2 = 0,099$ (médio) e 0,053 (pequeno). A correção não esta-

belece causalidade ou ausência de efeito, e sem comparações *post hoc* não se identificam pares diferentes (`analysis/rq06/rq06_resultados.md`).

Java tem 10 repositórios e C++ 13; 16 linguagens com menos de 10 foram agrupadas em "Outras" (51), o que reduz a resolução por linguagem. Há empates em CFR: 24 repositórios têm CFR (a) zero e 52, CFR (b) zero; as correções de postos não eliminam a informação limitada por esses valores (`analysis/rq05/rq05_resultados.md`; `analysis/README.md`).

Os ICs de Wilson tratam 283 releases como independentes, embora venham de 58 repositórios, e podem ser estreitos demais (`analysis/validacao_cfr_b/resultados.md`). Uma validação futura deve ser vinculada ao dataset congelado e preservar esse agrupamento na estimação dos intervalos.

6. Replicação cruzada

PENDENTE: o grupo aguarda o sorteio do professor. Ainda não há dados ou resultados de replicação.

Após o sorteio, Gustavo executará `python -m lab03.replication.compare` e preencherá esta seção com a saída e as divergências, conforme `Lab-03/docs/replicacao.md`.

Código e acompanhamento. Repositório: `https://github.com/lucasrsnd/lab-medicao-experimentacao`. GitHub Projects: `https://github.com/users/lucasrsnd/projects/2`.

Referências

Forsgren, N.; Humble, J.; Kim, G. (2018). *Accelerate: The Science of Lean Software and DevOps*. IT Revolution Press.

DORA. *DORA's software delivery performance metrics*. Disponível em: `https://dora.dev/guides/dora-metrics/`. Acesso em: 7 out. 2026.

GitHub. *REST API endpoints for commits*. Disponível em: `https://docs.github.com/en/rest/commits/commits`. Acesso em: 7 out. 2026.

Wohlin, C.; Runeson, P.; Höst, M.; Ohlsson, M. C.; Regnell, B.; Wesslén, A. (2012). *Experimentation in Software Engineering*. 2nd ed. Springer.